Predicción del Precio de Bolsa de Energía Eléctrica en Colombia

Entrega 1: Comprensión del Problema, EDA y Baseline

Aprendizaje de Máquina Aplicado — EAFIT

Profesor: Marco Teran

Abril 2026

1. Planteamiento del Problema

El mercado eléctrico colombiano opera mediante un mecanismo de despacho por mérito de precios, en el cual XM (el operador del sistema) ordena las ofertas de los generadores de menor a mayor costo y despacha hasta cubrir la demanda. El precio de bolsa corresponde al precio de la última planta despachada (precio marginal del sistema). Este proceso se repite cada hora del día, y los generadores deben presentar sus ofertas con un día de anticipación (*day-ahead*).

Pregunta de investigación: ¿Es posible predecir con suficiente precisión el precio de bolsa ponderado nacional del día siguiente usando variables del mercado energético colombiano disponibles públicamente en la API XM/SIMEM?

Justificación: La incertidumbre en el precio de bolsa representa un riesgo financiero significativo. Según literatura colombiana, la variación diaria equivale aproximadamente a $10M COP por GWh/día para agentes medianos. Un modelo de predicción confiable permite optimizar estrategias de oferta, planificar despachos y gestionar contratos.

Tipo de tarea ML: Regresión supervisada — variable objetivo continua (COP/kWh).

2. Descripción de los Datos

Fuente: API pública XM/SIMEM (simem.co). Los datos son de acceso público y corresponden al Operador del Sistema Interconectado Nacional de Colombia.

Tabla 1. *Variables descargadas de la API XM/SIMEM.*

Variable	Dataset ID	Descripción	Tipo
Precio de Bolsa Ponderado	96D56E	Variable objetivo — precio PPBO nacional diario	Target
Máximo Precio Ofertado	03ba47	MPO Nacional — señal de estrategia de oferta	Feature
Precio de Escasez	43D616	Techo regulatorio del mercado	Feature
Demanda Comercial	d55202	Demanda total del sistema (promedio, máx, pico 18-21h)	Feature
Generación Real por Tipo	E17D25	Generación hidro, térmica, solar, eólica, ratio hidro	Feature
Aportes Hídricos en Energía	BA1C55	Aportes hídricos total nacional	Feature

Variable	Dataset ID	Descripción	Tipo
Reservas Hidráulicas en %	843497	Nivel de embalses como % de capacidad útil	Feature

- **Rango temporal:** 2023-02-01 a 2026-03-31
- **Total de observaciones:** 1,125 días
- **Features totales después de ingeniería:** 22

3. Hallazgos del EDA

3.1 Estadísticas del precio de bolsa

- **Media:** ~471 COP/kWh | **Mediana:** ~350 COP/kWh | **Desv. Estándar:** ~400 COP/kWh
- **Mínimo:** ~102 COP/kWh | **Máximo:** ~3,683 COP/kWh
- **Coeficiente de variación:** >100% — alta volatilidad
- El precio presenta asimetría positiva (cola derecha): hay días de precio extremadamente alto

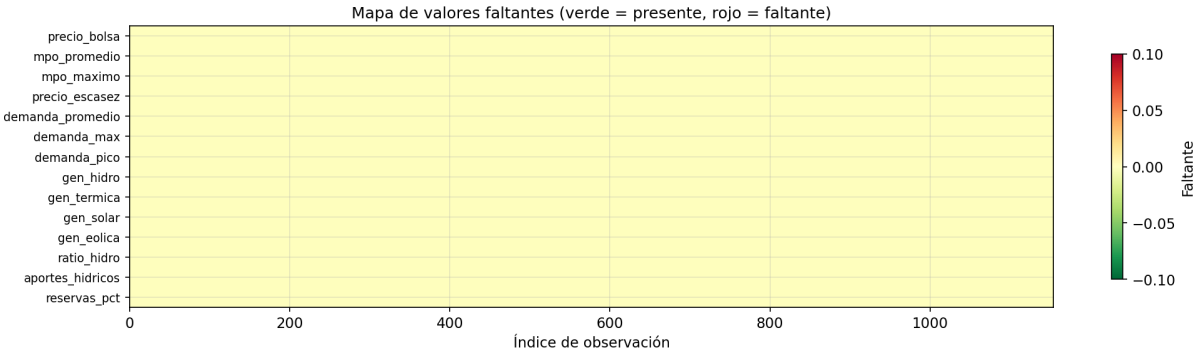

Figura 1. *Mapa de valores faltantes por variable y fecha.*

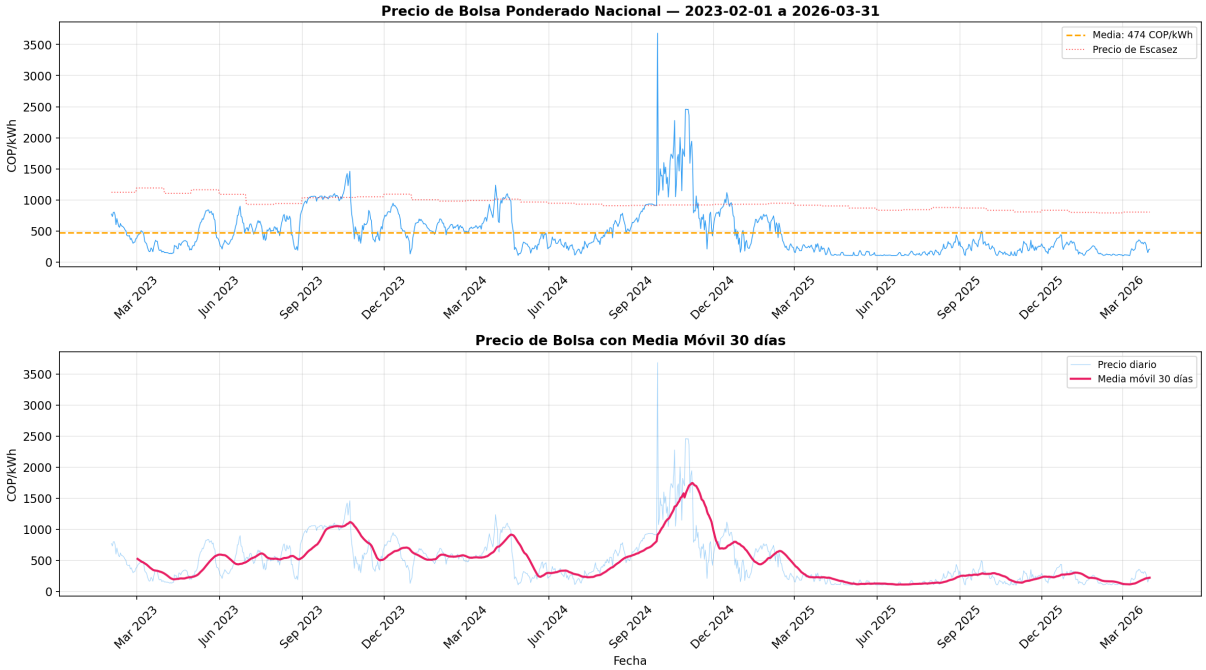

Figura 2. *Serie temporal del precio de bolsa ponderado nacional (COP/kWh).*

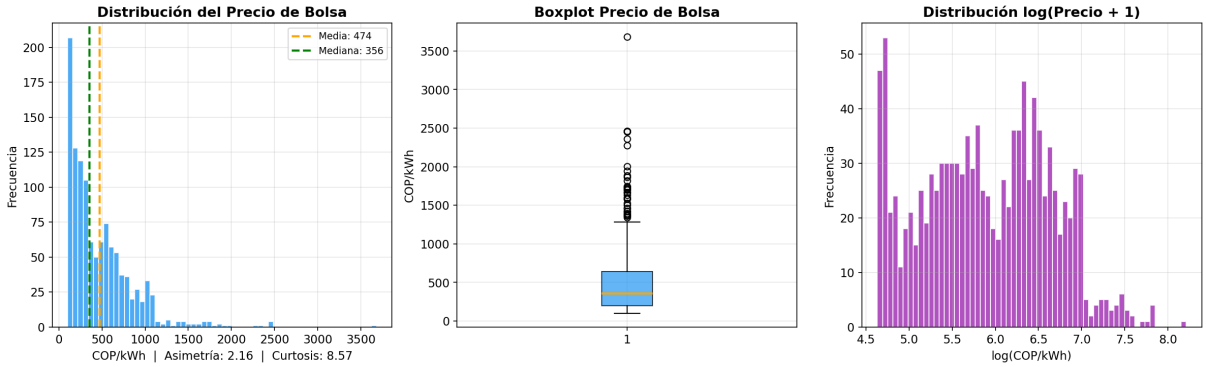

Figura 3. Distribución del precio de bolsa — histograma y boxplot.

3.2 Correlaciones principales con el precio de bolsa

Tabla 2. Correlaciones con el precio de bolsa (ordenadas por magnitud).

Variable	Correlación
MPO Promedio	+0.998
MPO Máximo	+0.847
Generación Térmica	+0.795
Ratio Hidro (%)	-0.774
Generación Hidro	-0.701
Demanda Máxima	-0.462
Aportes Hídricos	-0.461
Reservas Hidráulicas %	-0.374
Precio de Escasez	+0.285

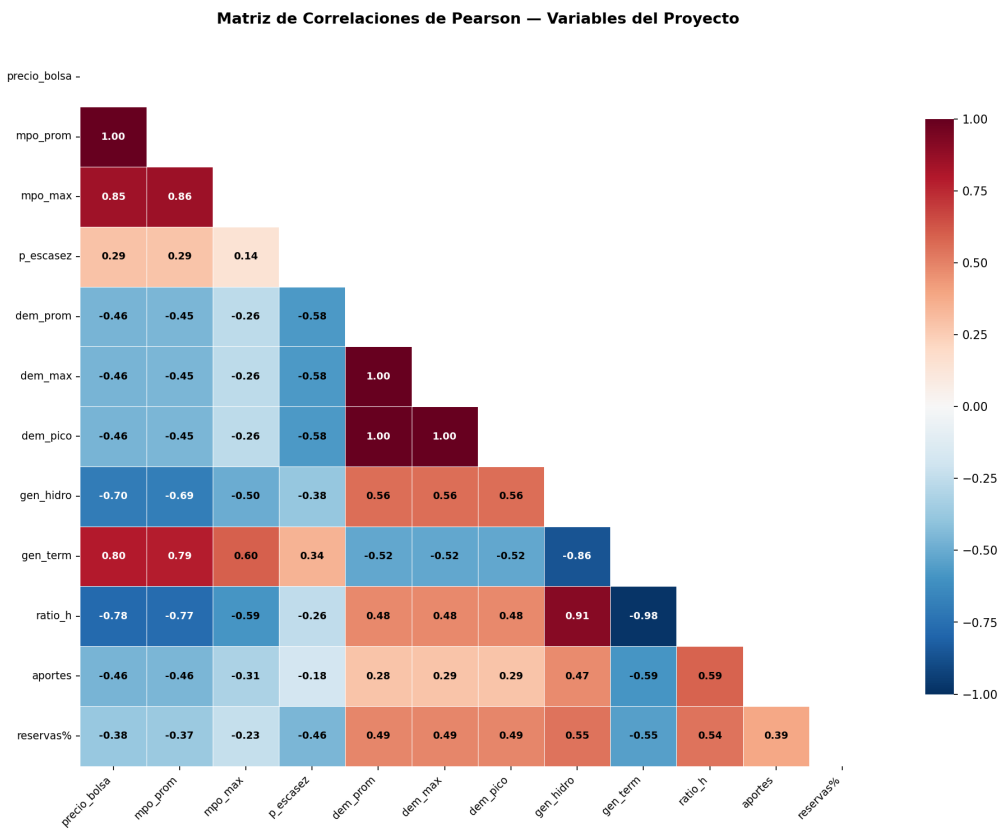

Figura 5. Matriz de correlaciones entre variables principales.

3.3 Patrones temporales

- **Precios más altos en temporada seca** (diciembre-marzo): menor generación hidráulica disponible.
- El precio del día siguiente está fuertemente correlacionado con el precio actual (**autocorrelación alta a lag=1**).
- La media del precio en el conjunto de prueba (jul 2025 - mar 2026) es **208.56 COP/kWh**, significativamente menor que la media histórica de los 3 años (~471 COP/kWh), lo que indica un periodo de precios bajos.

3.4 Calidad de datos

- Valores faltantes tratados con **interpolación lineal** (mecanismo MAR).
- No se detectaron duplicados.
- Los outliers (picos de precio) se conservan: son información real del mercado, no errores.

4. Métrica de Evaluación

Se utilizan dos métricas complementarias:

MAE (Error Absoluto Medio) — métrica principal: Directamente interpretable en COP/kWh. Robusto a valores extremos. Responde a la pregunta: "¿cuántos COP/kWh me equivoco en promedio?"

RMSE (Raíz del Error Cuadrático Medio) — métrica complementaria: Castiga errores grandes. Útil para detectar si el modelo falla en días de alta volatilidad. Sistemáticamente mayor que el MAE dado el alto coeficiente de variación del precio.

Ambas métricas también se reportan como porcentaje de la media del conjunto de prueba para facilitar la comparación entre modelos.

5. Baselines y Dificultad del Problema

Se construyeron tres baselines para establecer el nivel de referencia mínimo:

Tabla 3. *Resultados de los baselines en validación y test.*

Baseline	MAE (val)	RMSE (val)	MAE (test)	RMSE (test)	MAE/Media test
B1 — Persistencia	33.81	55.66	27.65	39.72	13.3%
B2 — Media Móvil 7d	46.43	73.56	43.41	57.08	20.8%
B3 — Reg. Lineal (lags)	44.80	60.62	38.75	49.47	18.6%

Descripción de los baselines:

- **B1 Persistencia:** precio_mañana = precio_hoy. Captura la fuerte autocorrelación a lag=1.
- **B2 Media Móvil 7 días:** promedio de los últimos 7 días. Suaviza volatilidad.
- **B3 Regresión Lineal:** modelo entrenado usando solo lags del precio y variables temporales.

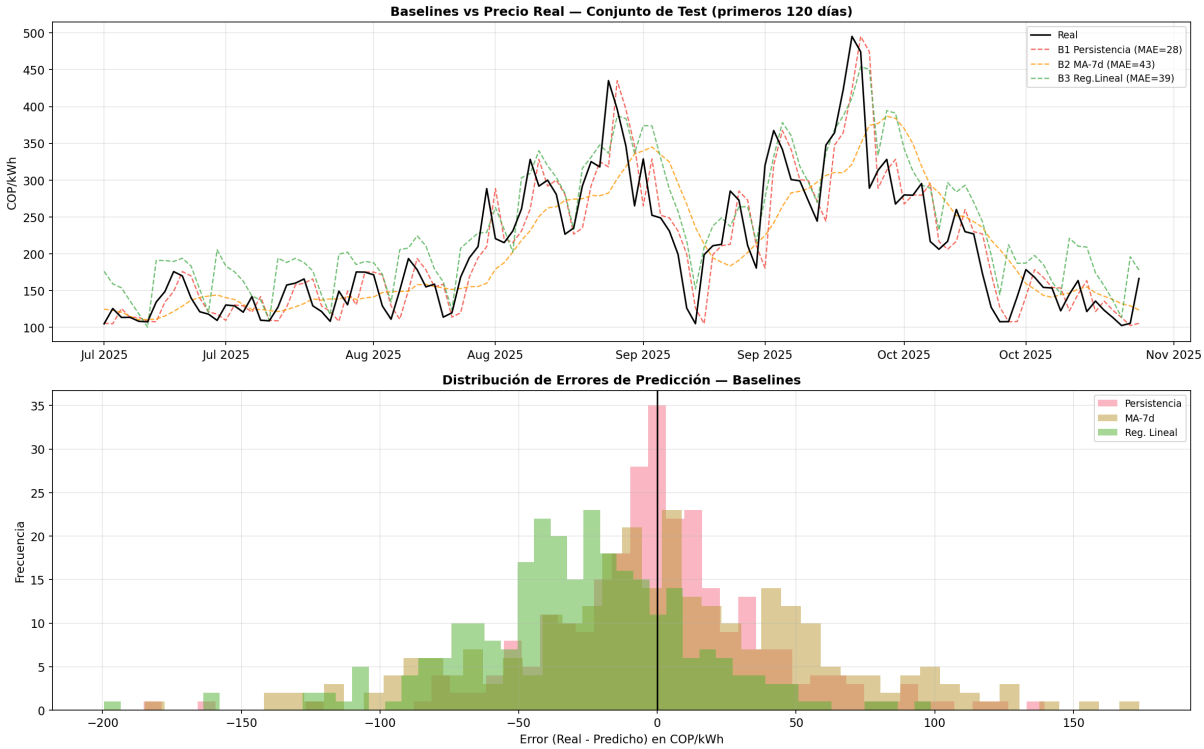

Figura 7. Comparación de baselines vs. precio real en el conjunto de test.

Conclusión sobre la dificultad: El problema es de dificultad media-alta. El baseline de persistencia (B1) logra un MAE de 27.65 COP/kWh en test (13.3% de error relativo), estableciendo un piso competitivo difícil de superar. Cualquier modelo de ML debe demostrar una mejora significativa sobre este baseline para justificar su complejidad.

6. Split Temporal

Tabla 4. División temporal del dataset.

Conjunto	Período	Observaciones	Proporción
Entrenamiento	2023-03-03 a 2024-12-31	670	59.6%
Validación	2025-01-01 a 2025-06-30	181	16.1%
Test	2025-07-01 a 2026-03-31	274	24.4%

División cronológica estricta para evitar *data leakage*. El conjunto de test no se toca hasta la evaluación final.

7. Conclusiones y Próximos Pasos

El EDA confirma que el precio de bolsa en Colombia está principalmente determinado por la dinámica hidro-térmica del sistema: cuando la generación hidráulica domina (ratio_hidro alto,

embalses llenos, aportes abundantes), los precios son bajos; cuando entra la generación térmica (más costosa), los precios suben. El MPO tiene correlación de 0.998 con el precio, lo que sugiere que la estrategia de oferta de los generadores es el principal determinante inmediato del precio.

Para la **Entrega 2** se compararán al menos dos familias adicionales de modelos (XGBoost/LightGBM y SARIMAX/VAR) contra los baselines usando validación temporal walk-forward, análisis de importancia de features y métricas MAE y RMSE.

Fuentes

1. González Pérez, L.F. & Urbano Buriticá, S.N. (2022). *Predicción de corto plazo del precio de bolsa de energía en el mercado colombiano*. Tesis de Maestría, Universidad de los Andes.

2. Villarreal Marimon, Y.J. & Flores San Martín, L.A. (2023). *Modelos de predicción del precio de la energía en bolsa en Colombia*. Tesis de Maestría, EAFIT.

3. XM S.A. E.S.P. — API SIMEM: https://www.simem.co